



ID/X PARTNERS — RAKAMIN ACADEMY
FINAL PROJECT DATA SCIENTIST INTERN

CREDIT RISK PREDICTION

BY MUHAMMAD GHAZA EKA PUTRA



OVERVIEW

Latar Belakang Masalah :

- Perusahaan multifinance menghadapi risiko gagal bayar dari nasabah.
- Penilaian kelayakan kredit secara manual tidak efisien dan rawan subjektivitas.

Tujuan :

- Mengembangkan sistem prediksi kelayakan kredit untuk mengklasifikasikan nasabah sebagai berisiko tinggi atau tidak.
- Mengurangi risiko kerugian akibat gagal bayar dan mendukung profitabilitas perusahaan.

Manfaat :

- Pengambilan keputusan kredit lebih cepat dan objektif.
- Mengurangi kerugian dari nasabah yang tidak mampu melunasi pinjaman.





DATASET OVERVIEW

UKURAN DATASET

- Total baris: 466.285
- Total kolom: 75

HIGHLIGHT


- Kolom **loan_status** adalah target untuk prediksi risiko kredit.
- Banyak kolom terkait dengan riwayat kredit, penghasilan, dan detail pinjaman.

TIPE DATA

- Float
- Objek
- Integer

KUALITAS DATA

- Terdapat banyak Missing Value
- Tipe data yang tidak sesuai
- Setiap baris data mewakili identitas individu





FEATURE ENGINEERING

DATA CLEANING

- Identifikasi kolom yang tidak digunakan
- Membersihkan setiap kolom yang ingin digunakan seperti melakukan transformasi data
- Fitur loan_status diencoding menjadi variabel biner bad_loan_status (1 = risiko, 0 = aman)

DATA TRANSFORMATION

Numeric Cleaning


- emp_length → hapus teks (“years”, “+”, “<”) → angka (emp_length_int).
- term → hapus kata “months” → angka jumlah bulan.

Date Transformation

- Kolom: earliest_cr_line, issue_d, last_pymnt_d, next_pymnt_d, last_credit_pull_d.
 - Langkah: ubah string → datetime, hitung selisih bulan dari tanggal referensi (2017-12-01).
- 

EXPLORATORY DATA ANALYSIS

- Cek Korelasi:
Sebagian besar fitur punya hubungan lemah dengan bad_loan_status, sehingga dibutuhkan gabungan banyak fitur untuk memprediksi risiko kredit.



EXPLORATORY DATA ANALYSIS

Cek cardinality data digunakan untuk mengetahui jumlah kategori unik

- Kategorikal Data:

grade	7
emp_title	205475
home_ownership	6
verification_status	3
pymnt_plan	2
purpose	14
title	63098
addr_state	50
initial_list_status	2
application_type	1
dtype: int64	

Menghapus kolom 'title', 'emp_title'
dan 'application_type'

- Numerik Data:

loan_amnt	1352	total_pymnt_inv	347659
funded_amnt	1354	total_rec_prncp	172713
funded_amnt_inv	9854	total_rec_int	270249
int_rate	506	total_rec_late_fee	5808
installment	55622	recoveries	22773
annual_inc	31901	collection_recovery_fee	20275
dti	3997	last_pymnt_amnt	198194
delinq_2yrs	24	collections_12_mths_ex_med	9
inq_last_6mths	28	policy_code	1
mths_since_last_delinq	145	acc_now_delinq	6
mths_since_last_record	123	bad_loan_status	2
open_acc	62	emp_length_int	10
pub_rec	26	term_int	2
revol_bal	58142	mths_since_earliest_cr_line	515
revol_util	1269	mths_since_issue_d	91
total_acc	112	mths_since_last_pymnt_d	98
out_prncp	135665	mths_since_next_pymnt_d	100
out_prncp_inv	141189	mths_since_last_credit_pull_d	103
total_pymnt	351609	dtype: int64	

Menghapus kolom 'policy_code'




EXPLORATORY DATA ANALYSIS

Univariate Analysis digunakan untuk menganalisis setiap variabel secara individu.


Salah satu hasil chart-nya:

- **Kategorikal Data:**



Grade: Sebagian besar pinjaman berada di grade B dan C, menunjukkan kualitas kredit menengah sebagai dominan.

- **Numerik Data:**




Int_rate: Mayoritas pinjaman dikenakan bunga sekitar 13–14%, menandakan tingkat bunga yang relatif moderat untuk sebagian besar peminjam.

EXPLORATORY DATA ANALYSIS

Bivariate Analysis digunakan untuk melihat hubungan antara fitur dengan target.
Salah satu hasil chart-nya:

- **Kategorikal Data:**



Variabel Grade menunjukkan tingkat risiko pinjaman yang diberikan oleh lender (A = paling rendah risiko, G = paling tinggi).

Dari grafik terlihat bahwa:

- **Grade A–C** didominasi oleh good loan (status 0), jumlah bad loan relatif kecil.
- **Grade D–G** memiliki proporsi bad loan lebih besar, dan semakin ke bawah (E–G) jumlah bad loan makin terlihat walaupun total peminjam lebih sedikit.
- **Insight** : Semakin rendah grade (mendekati G), semakin tinggi risiko gagal bayar.

DATA PREPROCESSING

CEK MISSING VALUE

```
mths_since_last_record      86.566585
mths_since_last_delinq      53.690554
mths_since_next_pymnt_d     48.728567
emp_length_int              4.505399
mths_since_last_pymnt_d     0.080637
revol_util                  0.072917
collections_12_mths_ex_med  0.031097
mths_since_last_credit_pull_d 0.009007
delinq_2yrs                 0.006219
pub_rec                     0.006219
inq_last_6mths              0.006219
open_acc                    0.006219
acc_now_delinq              0.006219
total_acc                   0.006219
mths_since_earliest_cr_line 0.006219
annual_inc                   0.000858
dtype: float64
```

Insight

- Terlihat beberapa fitur memiliki missing value
- Menghapus fitur yang memiliki banyak missing value dan fitur yang tidak dipakai
- Dalam kasus ini menghapus fitur :
'mths_since_last_record',
'mths_since_next_pymnt_d',
'mths_since_last_pymnt_d'

DATA IMPUTATION

```
df['mths_since_last_delinq'].fillna(-1, inplace=True),
df['emp_length_int'].fillna(0, inplace=True),
df['revol_util'].fillna(0, inplace=True),
df['collections_12_mths_ex_med'].fillna(0, inplace=True),
df['mths_since_last_credit_pull_d'].fillna(0, inplace=True),
df['delinq_2yrs'].fillna(0, inplace=True),
df['pub_rec'].fillna(0, inplace=True),
df['inq_last_6mths'].fillna(0, inplace=True),
df['open_acc'].fillna(0, inplace=True),
df['acc_now_delinq'].fillna(0, inplace=True),
df['total_acc'].fillna(0, inplace=True),
df['mths_since_earliest_cr_line'].fillna(0, inplace=True),
df['annual_inc'].fillna(df['annual_inc'].median(), inplace=True)
```

Missing value ditangani:

- Mengisi menggunakan nilai -1 (untuk menandai kondisi khusus seperti tidak pernah delinquency)
- Mengisi menggunakan nilai 0 (untuk variabel jumlah/kejadian),
- Mengisi menggunakan nilai median (untuk variabel pendapatan yang distribusinya skewed).

DATA PREPROCESSING: TRAIN-TEST SPLIT DATA

LABEL ENCODING

- Menggunakan LabelEncoder untuk variabel kategorikal

FITUR PREDIKSI (X)

- Total 36 Fitur

TARGET PREDIKSI (Y)

- bad_loan_status → 0 (bad), 1 (good)

TRAIN-TEST SPLIT

- Proporsi: 80% data latih, 20% data uji

IMBALANCE DATA

- menggunakan SMOTE: Oversampling

STANDARISASI

- Scaling: StandardScaler digunakan untuk menstandarkan semua fitur numerik




LOGISTIC REGRESSION

Hasil Model :

- Akurasi: 80%
Model mampu mengklasifikasikan 8 dari 10 data dengan benar
- Precision: 73%
Dari semua prediksi bad loan, hanya 72.9% yang benar-benar bad loan.
- Recall: 96%
Model hampir selalu berhasil mendeteksi bad loan yang sebenarnya.
- F1-score: 83%
Model cukup seimbang namun recall lebih dominan.
- ROC AUC Score: 0.99
Model sangat baik membedakan antara good loan dan bad loan.

ROC Curve: Training Model



=== Evaluation on Test Set ===

Accuracy : 0.8006043569076671
Precision: 0.7291599687686584
Recall : 0.9561551433389545
F1 Score : 0.8273705604919613
ROC-AUC : 0.9859499713194053

Confusion Matrix:

```
[[53622 29485]  
 [ 3640 79380]]
```


RANDOM FOREST

Hasil Model :

- Akurasi: 99%
Model dapat mengklasifikasikan status pinjaman dengan tingkat ketepatan yang sangat tinggi.
- Precision: 99%
Hampir semua prediksi pinjaman bermasalah benar-benar termasuk kategori bermasalah.
- Recall: 98%
Model mampu menangkap sebagian besar pinjaman bermasalah secara benar.
- F1-score: 99%
Keseimbangan antara precision dan recall sangat baik, menunjukkan performa model yang konsisten.

```
Accuracy: 0.9897307481625504
Precision: 0.997698616721753
Recall: 0.9817152493375091
F1-Score: 0.989642401797098
```

```
Confusion Matrix:
[[82919   188]
 [ 1518 81502]]
```

Classification Report:

	precision	recall	f1-score	support
0	0.98	1.00	0.99	83107
1	1.00	0.98	0.99	83020
accuracy			0.99	166127
macro avg	0.99	0.99	0.99	166127
weighted avg	0.99	0.99	0.99	166127



KESIMPULAN PROJECT

- Kedua model (Logistic Regression dan Random Forest) mampu mendeteksi status pinjaman dengan performa yang cukup baik
- Logistic Regression unggul dalam recall (95.6%), sehingga lebih baik dalam menangkap sebagian besar nasabah berisiko, meskipun precision masih terbatas (73%).
- Random Forest menunjukkan performa keseluruhan yang lebih unggul dengan akurasi tinggi (98.9%), precision hampir sempurna (99.7%), serta recall yang tetap sangat baik (98.1%).
- Dengan keseimbangan precision dan recall yang lebih tinggi, Random Forest menjadi model terbaik untuk digunakan dalam mendeteksi nasabah berisiko gagal bayar.
- Implementasi model ini dapat membantu perusahaan meminimalkan risiko kredit macet sekaligus menjaga kualitas portofolio pinjaman.



THANK YOU

✉ ghazaputra99@gmail.com

in <https://www.linkedin.com/in/ghazaputra99>

🐙 <https://github.com/ghaza-putra>

